Azure OpenAI

IA Générative RGPD — Données en Europe

Option Premium

En bref

Azure OpenAI est la version souveraine de l'API OpenAI hébergée dans les datacenters Microsoft en Union Européenne. Fonctionnellement identique à l'API OpenAI classique (mêmes modèles GPT-4o, GPT-4o-mini), elle offre une garantie RGPD stricte : les données traitées ne quittent jamais l'UE et ne sont pas utilisées pour l'entraînement des modèles. À utiliser pour les clients sensibles : cabinets juridiques, médicaux, RH, finance.

Point clé

Azure OpenAI est un **argument commercial fort** avec les grands comptes et les secteurs réglementés. La différence de prix vs OpenAI standard est marginale (+10–20%) pour une conformité RGPD garantie contractuellement par Microsoft.

1 Ce que voit le client

Ce que voit et ressent le client

« J'ai les mêmes capacités IA qu'OpenAI — résumés, rédaction, analyse — mais mes données ne quittent jamais l'Union Européenne. Mon avocat et mon DPO ont validé l'usage. Je peux mettre en place l'IA sur nos dossiers clients sensibles sans risque juridique. »

Gains mesurables :

- **Conformité RGPD** stricte et contractuelle avec Microsoft
- Argument de confiance décisif pour les clients grands comptes et secteurs réglementés
- Mêmes performances que l'API OpenAI — **zéro compromis technique**
- Traitement possible de données personnelles, médicales, juridiques

2 Installation technique

Étape 1 — Créer la ressource Azure OpenAI :

Listing 1 – Azure Portal — Création de la ressource

```
# Azure Portal → Créer une ressource → Azure OpenAI
# Paramètres :
#   Subscription: Votre abonnement Azure
#   Resource group: rg-jlax-client-nom
#   Region: France Central (ou Sweden Central pour EU)
#   Name: jlax-client-nom-openai
#   Pricing tier: Standard S0
# → Valider et attendre la création (2-5 minutes)
```

Étape 2 — Déployer un modèle :

```
# Azure OpenAI Studio (oai.azure.com) → Deployments → Create
# Model: gpt-4o-mini (recommandé) ou gpt-4o (tâches complexes)
# Deployment name: gpt4omini-prod  (note: pas de points dans le nom)
# Tokens Per Minute Rate Limit: 100K TPM (ajuster selon usage)
```

Étape 3 — Récupérer les identifiants :

```
# Azure OpenAI Studio → Settings → Resource
```

```
# Endpoint: https://jlax-client-nom-openai.openai.azure.com/
# API Key: xxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx (Keys and Endpoint)
# Deployment name: gpt4omini-prod
# API Version: 2024-02-01 (vérifier la dernière version stable)
```

Étape 4 — Configurer dans n8n :

1. n8n → Credentials → Add → **Azure OpenAI**
2. Resource Name : `jlax-client-nom-openai`
3. API Key : coller la clé Azure
4. Dans les nodes OpenAI : sélectionner **Azure** comme provider
5. Deployment Name : `gpt4omini-prod`

3 Configuration de base

Différences API vs OpenAI standard (adapter les workflows n8n) :

Paramètre	OpenAI classique	Azure OpenAI
Endpoint URL	`api.openai.com`	`*.openai.azure.com`
Nom du modèle	`gpt-4o-mini`	nom du déploiement
Auth header	`Authorization: Bearer`	`api-key:`
Données en EU	Non (US par défaut)	Oui (choix de région)
Formation modèle	Possible	Non (contractuel)

Utilisation dans Flowise :

— Flowise → Credentials → Add → **Azure ChatOpenAI**
— Renseigner les mêmes paramètres : Resource Name, API Key, Deployment Name
— Tous les assistants RAG peuvent basculer d'OpenAI à Azure en changeant la credential

4 Intégration dans la stack

Outil	Usage avec Azure OpenAI
n8n	Remplacement transparent d'OpenAI API (même nodes, autre credential)
Flowise	Embeddings + chat pour les assistants RAG sur données sensibles
MS Graph API	Traitement des emails/documents M365 avec IA souveraine EU

5 Rendre invisible côté client

— Le client ne voit pas la différence entre OpenAI et Azure OpenAI — même résultats
— L'argument de vente : « **nos IA sont hébergées en France** » — fort auprès des directions
— La facturation Azure OpenAI est incluse dans la facture mensuelle Jlax
— Basculement OpenAI → Azure OpenAI : changer uniquement la credential dans n8n/Flowise

Maintenance mensuelle

- ☐ Vérifier la consommation mensuelle dans Azure Portal → Cost Management
- ☐ Contrôler les limites de débit (TPM) : aucun throttling dans les logs n8n
- ☐ Vérifier que les déploiements de modèles sont toujours actifs
- ☐ Mettre à jour l'API Version si une nouvelle version stable est disponible

- ☐ Renouveler les clés API si rotation de sécurité requise (tous les 6 mois)